
Rapport d'avancement de thèse

Première année de doctorat

Federated Time Series Foundation Models pour la Maintenance Prédicative Industrielle Multi-Domaine

Préparé par : Yassire AMMOURI
Directeur de thèse : Pr. Younes Karfa Bakali
Encadrant : Mme Rajaa SAIDI
Université : Université Mohammed V, Faculté des Sciences de Rabat
Laboratoire : LRIT (Laboratoire de Recherche en Informatique et Télécommunications)
Date : 31 mars 2026

Ce rapport couvre l'ensemble des activités réalisées depuis le début de la thèse, incluant le bilan personnel, la revue bibliographique, l'identification des problématiques, et la planification des contributions.

Table des matières

Avant-propos : Activités récentes et progrès	3
1. Formations et certifications suivies	3
2. Avancement de la rédaction scientifique	3
3. Activités d’enseignement	6
1 Contexte général du sujet	7
1.1 L’évolution de la maintenance industrielle	7
1.2 Le problème fondamental : des données utiles mais inaccessibles	8
1.3 Positionnement de la thèse	8
2 Concepts de base	9
2.1 L’apprentissage fédéré (Federated Learning)	9
2.2 Les séries temporelles industrielles	9
2.3 La maintenance prédictive	10
2.4 Les Foundation Models pour séries temporelles	10
3 État de l’art	12
3.1 Cartographie du domaine de recherche	12
3.2 Foundation Models pour séries temporelles	12
3.2.1 Panorama des modèles existants (2023–2024)	12
3.2.2 Limitations dans le contexte industriel	12
3.3 Federated Learning pour Foundation Models	14
3.3.1 Stratégies de personnalisation fédérée (NLP/Vision)	14
3.3.2 Transposition aux séries temporelles	14
3.4 Federated Time Series Foundation Models : les trois travaux existants	15
3.4.1 Tableau comparatif des travaux à l’intersection	15
3.4.2 Analyse critique par travail	15
3.5 Federated Learning et Maintenance Prédictive	16
3.5.1 Travaux FL appliqués à la maintenance	16
3.5.2 Constat majeur : absence de Foundation Models	16
4 Problématiques identifiées	17
4.1 P1 — La personnalisation fédérée sur données hétérogènes	17
4.2 P2 — L’absence de benchmark fédéré standardisé	17
4.3 P3 — L’incompatibilité architecturale des TS FMs avec le FL	18
4.4 P4 — L’inadéquation aux données industrielles réelles	18
4.5 Synthèse : carte des gaps	19

5	Contributions envisagées	20
5.1	Vue d'ensemble du plan de contributions	20
5.2	C1 — FedPEFT-TS : personnalisation fédérée pour TS FMs	20
5.3	C2 — FedTS-Bench : benchmark fédéré pour la maintenance industrielle	21
5.4	C3 — FedTSFM-Arch : architecture TS FM native FL	21
5.5	C4 — IndusFedFM : validation industrielle multi-domaines	21
6	Contenu des publications prévues	23
6.1	Stratégie de publication	23
6.2	Détail par publication	23
6.3	Fil narratif de la thèse	24
7	Conférences et journaux ciblés	25
7.1	Conférences — soumissions rapides (P1, P2)	25
7.2	Journaux — contributions majeures (P3, P4)	25
7.3	Stratégie de soumission recommandée	25
8	Plan de travail et prochaines étapes	27
8.1	Priorités immédiates (2025-2026)	27
8.2	Calendrier prévisionnel sur 3 ans	27
8.3	Cohérence d'ensemble	27

Avant-propos : Activités récentes et progrès

Ce premier chapitre présente un bilan honnête de ce qui a été accompli depuis le début de la thèse. Il ne s'agit pas d'un état des lieux de la recherche, mais d'un inventaire personnel : les formations suivies, les articles en cours, et les responsabilités pédagogiques assumées. Ce contexte est indispensable pour que les directeurs de thèse puissent évaluer la charge de travail réelle et guider les priorités des prochains mois.

1. Formations et certifications suivies

Au cours de cette première période de thèse, un effort important a été fourni pour se former aux outils et aux pratiques de la recherche scientifique. Les formations ci-dessous ont toutes été complétées :

Ce que ces formations apportent concrètement : maîtriser ces outils signifie être capable de conduire une revue de littérature rigoureuse, identifier les bons journaux pour soumettre, et comprendre les mécanismes de la propriété intellectuelle qui entourent les contributions de recherche. C'est un socle essentiel pour toute la suite du doctorat.

2. Avancement de la rédaction scientifique

Deux travaux de rédaction sont actuellement en cours. Leur avancement est détaillé ci-dessous de façon transparente, y compris les difficultés rencontrées.

2a. Article issu du mémoire de Master

Cet article porte sur le framework d'apprentissage fédéré centré sur les données développé dans le cadre du mémoire de Master, appliqué à la maintenance prédictive des éoliennes à partir de données SCADA. L'algorithme d'agrégation utilisé est **FedProx**, choisi pour sa robustesse face à l'hétérogénéité des données entre clients.

État d'avancement par section :

Description du problème de résultats :

Deux difficultés majeures bloquent la finalisation de cette section :

TABLE 1 – Certifications obtenues en première année

Organisme	Description de la formation	Progressent
WIPO — DL101	Introduction à la propriété intellectuelle. Formation en ligne de l'Organisation Mondiale de la Propriété Intellectuelle couvrant les brevets, droits d'auteur, marques et secrets commerciaux. Compétence utile pour protéger les futures contributions algorithmiques ou logicielles de la thèse.	complète
Wiley	Formation à la publication scientifique : comprendre le processus de soumission, la révision par les pairs, et les bonnes pratiques d'écriture académique.	1 Certif
Scopus (Elsevier)	Maîtrise de la base de données bibliographique Scopus : recherche avancée, analyse de citations, identification des journaux et des tendances dans un domaine.	1 Certif
Springer Nature	Formation à l'utilisation de la plateforme Springer pour la recherche bibliographique et la compréhension des politiques de publication en accès ouvert.	1 Certif
Taylor & Francis	Formation aux outils de recherche et de publication du groupe Taylor & Francis, incluant les journaux spécialisés en ingénierie et en informatique.	5 Certif
Clarivate (Web of Science)	Utilisation de Web of Science pour les recherches bibliographiques, l'analyse des facteurs d'impact et le suivi des indicateurs bibliométriques.	10 Certif

- (i) **Faible performance du modèle central.** Les modèles de classification multi-classe testés (sur les données SCADA éoliennes) n'atteignent pas des niveaux de précision satisfaisants. Cela peut être lié à la qualité du prétraitement des données, à un déséquilibre de classes non traité, ou à un choix de modèle inadapté. Des investigations sont en cours pour identifier la cause exacte.
- (ii) **Impossibilité d'obtenir des résultats d'entraînement fédéré.** Le pipeline d'entraînement FL (FedProx) ne produit pas encore de résultats stables ou exploitables. Le processus de refactorisation et de débogage est en cours.

Plan d'action pour débloquent cet article :

- Vérifier et corriger le pipeline de prétraitement des données SCADA (normali-

Section	Contenu	Statut
Introduction	Contexte, motivation, contributions	En attente
Related Work	Revue FL + maintenance éolienne	Rédigée
Méthodologie	Framework data-centric + FedProx	Rédigée
Expériences	Setup, datasets SCADA, protocoles	Rédigée
Résultats	Classification multi-classe, évaluation FL	Bloquée
Conclusion	Synthèse et perspectives	En attente

- sation, gestion des valeurs manquantes, équilibrage des classes).
- Tester des modèles de référence simples (Random Forest, SVM) avant les modèles profonds pour établir un plancher de performance.
 - Déboguer l'implémentation FedProx pas à pas, en commençant par un scénario à deux clients seulement.
 - Cibler **IEEE Transactions on Industrial Informatics (TII)** ou **Renewable Energy** (Q1, Elsevier) pour la soumission finale.

2b. Revue systématique de littérature (SLR)

Ce deuxième article vise à produire une revue systématique de la littérature sur les *Federated Time Series Foundation Models* pour la maintenance industrielle, en suivant la méthodologie PRISMA (*Preferred Reporting Items for Systematic Reviews and Meta-Analyses*).

Protocole PRISMA — Résultats préliminaires :

La démarche PRISMA repose sur un processus d'entonnoir : identifier un grand nombre de documents, puis les filtrer progressivement pour ne retenir que les plus pertinents.

TABLE 2 – Résultats du processus de sélection PRISMA

Étape	Description	Résultat
Identification	Requêtes sur IEEE Xplore, Scopus, Web of Science	3,000
Dédoublonnage	Suppression des doublons entre bases	1,700
Criblage des titres	Exclusion des articles hors sujet sur titre/résumé	361
Éligibilité	Lecture complète, vérification des critères	181
Inclusion finale	Articles retenus pour la synthèse	181

Requêtes utilisées (exemples) :

- *“Federated Learning” AND “Time Series” AND “Foundation Model”*
- *“Federated” AND “Predictive Maintenance” AND “Deep Learning”*
- *“Time Series Foundation Model” AND “Industrial”*
- *“FedAvg” OR “FedProx” AND “SCADA” OR “vibration” OR “anomaly detection”*

État actuel : une liste de références pertinentes a été constituée mais n’est pas encore formellement structurée selon la taxonomie PRISMA. La prochaine étape est de formaliser cette liste et de compléter les chiffres du tableau ci-dessus.

3. Activités d’enseignement

En parallèle de la recherche, des responsabilités pédagogiques ont été assumées en tant que chargé de Travaux Dirigés (TD) et de Travaux Pratiques (TP) :

Module	Description	Type d’intervention
Traitement du Signal	Encadrement des séances de TD pour le module de traitement du signal pour la premier année licence branch AI. Préparation des exercices, correction, et accompagnement des étudiants.	TD
Machine Learning	Encadrement des séances de TP pour un module d’apprentissage automatique, pour les étudiants de la première année licence branch PC. Aide aux étudiants sur les implémentations pratiques, correction des travaux et démonstrations en salle.	TP

Ces activités représentent un investissement en temps non négligeable. Elles développent cependant des compétences de communication et de pédagogie qui bénéficient directement à la qualité de la recherche, notamment pour la présentation des travaux lors de conférences.

1. Contexte général du sujet

1.1 L'évolution de la maintenance industrielle

Pendant longtemps, les industries ont géré leurs équipements de deux façons simples : soit on attend la panne pour réparer (*maintenance corrective*), soit on effectue des vérifications à intervalles réguliers, indépendamment de l'état réel de la machine (*maintenance préventive*). Ces deux approches ont leurs limites. La première expose à des arrêts non planifiés coûteux ; la seconde gaspille du temps et des ressources sur des équipements qui n'en ont pas besoin.

L'avènement des capteurs industriels et de l'apprentissage automatique a rendu possible une troisième voie : la **maintenance prédictive**. L'idée est d'observer en continu les signaux produits par les machines (vibrations, température, consommation électrique, données SCADA) et d'en déduire, avant la panne, que quelque chose ne va pas. Plutôt que de subir la défaillance ou d'intervenir inutilement, on agit au bon moment.

TABLE 1.1 – Évolution des approches de maintenance

Approche	Principe	Limite principale
Corrective	On répare après la panne	Arrêts non planifiés, coûts élevés
Préventive	On intervient à intervalles fixes	Gaspillage, interventions inutiles
Prédictive	On anticipe la panne via les données	Nécessite données et modèles IA
Prescriptive	L'IA recommande automatiquement l'action	Niveau de maturité encore faible

Les chiffres illustrent l'importance de ce changement de paradigme : on estime que 70 % des pannes industrielles sont précédées de signaux détectables dans les données, et que la maintenance prédictive peut réduire les coûts de maintenance de 40 % dans certains secteurs. Le marché mondial de cette technologie est estimé à plus de 630 milliards de dollars d'ici 2028.

1.2 Le problème fondamental : des données utiles mais inaccessibles

La maintenance prédictive dépend de la quantité et de la qualité des données disponibles pour entraîner les modèles. En théorie, plus on centralise des données provenant de nombreux sites et équipements, meilleurs sont les modèles. En pratique, cette centralisation est rarement possible, pour plusieurs raisons :

- **Confidentialité et concurrence.** Les données de production ou de performance d'une usine sont stratégiquement sensibles. Aucun opérateur industriel ne souhaite partager ses données brutes avec ses concurrents.
- **Réglementations.** Le RGPD et diverses réglementations sectorielles encadrent strictement les transferts de données, notamment dans l'énergie ou la défense.
- **Volume.** Un parc d'éoliennes peut générer des dizaines de gigaoctets de données par jour. Centraliser tout cela n'est ni pratique, ni économique.
- **Hétérogénéité.** Chaque domaine industriel produit des données différentes : un signal SCADA d'éolienne n'a rien à voir avec les données acoustiques d'une ligne de production ou avec les mesures thermiques d'un système HVAC.

Cette situation crée un paradoxe : les données les plus utiles pour améliorer la maintenance sont précisément celles qu'on ne peut pas partager. La question centrale devient alors : *comment entraîner de bons modèles sans jamais voir les données brutes des autres ?*

1.3 Positionnement de la thèse

C'est exactement à cette question que cette thèse cherche à répondre, en combinant trois champs de recherche :

- **Le Federated Learning (FL)**, qui permet d'entraîner des modèles collectivement sans centraliser les données.
- **Les Foundation Models pour séries temporelles**, qui permettent de construire des modèles puissants, pré-entraînés sur de grandes quantités de données, adaptables à de nombreuses tâches avec peu d'effort.
- **La maintenance prédictive industrielle multi-domaine**, qui est l'application cible : anticiper les pannes sur des équipements variés (éoliennes, systèmes HVAC, machines de production) sans partager les données de terrain.

La proposition centrale de la thèse : développer un framework basé sur des Foundation Models de séries temporelles, entraînés de façon fédérée sur des données industrielles hétérogènes, capable de s'adapter à plusieurs domaines avec un minimum de personnalisation — et ce, sans que les données brutes ne quittent jamais les sites locaux.

Cette vision n'est pas encore réalisée dans la littérature. C'est précisément l'espace blanc que cette thèse vise à combler.

2. Concepts de base

Ce chapitre présente les quatre piliers théoriques qui structurent le sujet de thèse. L'objectif n'est pas de les définir de façon exhaustive, mais de donner à tout lecteur une compréhension claire et fonctionnelle de chacun.

2.1 L'apprentissage fédéré (Federated Learning)

L'apprentissage fédéré est une méthode d'entraînement de modèles de machine learning dans laquelle les données restent sur les appareils ou sites qui les produisent. Au lieu d'envoyer les données vers un serveur central, on envoie uniquement les *mises à jour du modèle* (les poids, les gradients).

Le déroulement classique est le suivant :

1. Un serveur central distribue un modèle global à tous les clients.
2. Chaque client entraîne ce modèle localement sur ses propres données.
3. Chaque client envoie au serveur uniquement les mises à jour calculées, pas les données brutes.
4. Le serveur agrège ces mises à jour (par exemple en faisant une moyenne pondérée) pour produire un nouveau modèle global amélioré.
5. Le cycle recommence.

FedProx est l'algorithme utilisé dans le travail issu du Master. C'est une extension de l'algorithme standard (FedAvg) qui ajoute un mécanisme de contrôle pour éviter que les clients ne s'éloignent trop du modèle global lors de l'entraînement local. Cela le rend plus robuste quand les données des différents clients sont très dissemblables (situation appelée *non-IID*).

Le défi majeur en FL est précisément cette hétérogénéité : les données de chaque client peuvent avoir des distributions, des formats ou des volumes très différents. C'est particulièrement vrai dans le contexte industriel, où chaque site a ses propres capteurs, ses propres conditions d'exploitation et ses propres types de pannes.

2.2 Les séries temporelles industrielles

Une série temporelle est une séquence de mesures enregistrées à intervalles réguliers dans le temps. Dans le contexte industriel, cela couvre les signaux de capteurs de vibration, de température, de pression, de consommation électrique, ou encore les données SCADA des éoliennes.

Ces séries présentent des caractéristiques qui compliquent leur analyse :

- Elles sont souvent **multivariées** (plusieurs capteurs simultanément).
- Elles sont **non-stationnaires** : les conditions changent dans le temps (charge de la machine, saison, usure).
- Les défaillances sont des **événements rares** : les données sont fortement déséquilibrées (peu de pannes, beaucoup d'état normal).
- Elles contiennent du **bruit**, des valeurs manquantes et des anomalies de capteurs qui ne correspondent pas à de vraies pannes.

Dans un cadre fédéré, ces difficultés sont amplifiées : chaque client peut avoir des fréquences d'échantillonnage différentes, des longueurs de séries variables, et des types de défaillances propres à ses équipements.

2.3 La maintenance prédictive

La maintenance prédictive consiste à utiliser les données issues des capteurs pour anticiper l'état futur d'un équipement et planifier les interventions au bon moment. Les principales tâches associées sont :

- **Détection d'anomalies** : identifier un comportement anormal.
- **Classification de défaillances** : reconnaître le type de panne parmi plusieurs catégories possibles (tâche principale de cette thèse).
- **Estimation de la durée de vie résiduelle (RUL)** : prédire combien de temps il reste avant la panne.
- **Prévision de l'état de santé** : suivre l'évolution globale d'un indicateur de santé machine.

2.4 Les Foundation Models pour séries temporelles

Un Foundation Model est un grand modèle pré-entraîné sur un corpus massif et hétérogène de données, puis adapté à diverses tâches en aval avec peu d'exemples et peu de réentraînement. Le principe vient du traitement du langage naturel : GPT ou BERT sont des Foundation Models pour le texte. L'idée a depuis été étendue aux images, puis aux séries temporelles.

Les principaux Foundation Models pour séries temporelles apparus entre 2023 et 2024 sont :

Ce qui est révolutionnaire avec ces modèles, c'est leur capacité à fonctionner en **zero-shot** ou **few-shot** : sans entraînement spécifique sur un nouveau domaine, ils peuvent déjà produire des prédictions raisonnables. Cela ouvre la possibilité d'un modèle unique capable de servir de nombreux équipements industriels différents.

Le chaînon manquant : aucun de ces Foundation Models n'a été conçu pour être entraîné de façon fédérée. Et aucun d'eux n'a été évalué sur des données industrielles

TABLE 2.1 – Principaux Foundation Models pour séries temporelles (2023–2024)

Modèle	Année	Architecture et particularités	Tâches principales
TimesFM	2024	Transformer décodeur, pré-entraîné sur 100 Mds de points	Prévision
Moirai	2024	Encodeur masqué avec mélange d'experts, multi-fréquence	Prévision + anomalie
MOMENT	2024	Encodeur-décodeur (type T5), famille de modèles pour tâches multiples	Prévision + classification
Lag-Llama	2023	Transformer décodeur, probabiliste, univarié	Prévision
UniTime	2023	Transformer avec prompts de domaine, multi-domaine	Prévision
TimeLLM	2022	LLM (GPT-2) réutilisé pour les séries temporelles	Prévision

réelles (vibration, SCADA, acoustique). C'est précisément le double gap que cette thèse explore.

3. État de l’art

3.1 Cartographie du domaine de recherche

La recherche sur l’apprentissage fédéré de Foundation Models pour séries temporelles s’articule autour de trois axes principaux, illustrés dans la figure 3.1.




FIGURE 3.1 – Cartographie des domaines de recherche et leur intersection. Les flèches pleines indiquent les contributions directes, les flèches pointillées les inspirations méthodologiques.

3.2 Foundation Models pour séries temporelles

3.2.1 Panorama des modèles existants (2023–2024)

Les Foundation Models pour séries temporelles constituent un domaine émergent, avec la publication entre 2023 et 2024 de plusieurs architectures majeures pré-entraînées sur de larges corpus de données publiques.

3.2.2 Limitations dans le contexte industriel

Ces modèles présentent quatre limitations majeures pour la maintenance prédictive :

TABLE 3.1 – Niveaux de maturité de la littérature par axe de recherche

Domaine	Description	Maturité	Nb. travaux
FL général	Algorithmes d'agrégation (FedAvg, Fed-Prox), hétérogénéité, privacy	Mature	1000+
TS FMs centr.	TimesFM, Moirai, MOMENT, Lag-Llama, UniTime	Émergent	8 modèles
FL pour NLP/Vision	LoRA fédéré, adapters, split learning, quantization	Émergent	50 travaux
FL pour maintenance	Pruckovskaja et al. (2023), OASEES (2026), turbofan 2024	Initial	10 travaux
FL + TS FM	Time-FFM, Ali et al., FedForecaster	Quasi vide	3 travaux
FL + TS FM + PM	Aucun travail publié	Vierge	0

TABLE 3.2 – Comparaison des principaux Foundation Models pour séries temporelles

Modèle	Année	Architecture et particularités	Tâches	Params
TimesFM	2024	Transformer décodeur, pré-entraîné sur 100Mds points, contexte 16k	Prévision	200M
Moirai	2024	Encodeur masqué, MoE, multi-fréquence, LOTSA (320M pts)	Prév. + Anomalie	32–480M
MOMENT	2024	Architecture T5-like, Time-Series Pile, multi-tâches	Prév. + Classif.	385M
Lag-Llama	2023	Décodeur probabiliste, features lagged, univarié	Prévision	100M
UniTime	2023	Domain prompts, multi-domaine, Language-TS Transformer	Prévision	ND
TimeLLM	2022	GPT-2 reprogrammé, tokenization texte, LoRA fine-tuning	Prévision	345M
Timer-S1	2026	Sparse MoE (8.3B total), TimeBench (1T pts), contexte 11.5k	Prévision	750M actifs

- 1. Distribution des données d'entraînement.** Pré-entraînement sur données publiques (météo, trafic web, finance) via LOTSA ou TimeBench, sans données industrielles réelles (vibrations, SCADA, acoustique).

2. **Support multivarié limité.** Conçus principalement pour séries univariées ou faible dimension, alors que les données industrielles comportent souvent 100+ capteurs.
3. **Absence d'évaluation maintenance.** Aucun test sur classification de défaillances ou détection d'anomalies industrielles.
4. **Non-conception pour le FL.** Aucune propriété *federation-friendly* (patching adaptatif, mise à jour sparse, quantization-aware).

Écart de performance estimé : Les tests préliminaires suggèrent une perte de performance de 25–50% lors de l'application de TS FMs sur données industrielles réelles sans fine-tuning spécifique.

3.3 Federated Learning pour Foundation Models

3.3.1 Stratégies de personnalisation fédérée (NLP/Vision)

La communauté NLP/Vision a développé des techniques d'adaptation efficace en paramètres (PEFT) pour le FL de grands modèles. Le tableau suivant synthétise les approches potentiellement transférables aux séries temporelles.

TABLE 3.3 – Stratégies de personnalisation fédérée pour Foundation Models (inspirations NLP/Vision)

Méthode	Auteurs (Année)	Principe	Gain
FedCLIP	Wang et al. (2023)	Adapters sur backbone gelé, agrégation des adapters uniquement	283× vitesse
FedOPAL	Tupper & Gagné (2025)	Dual LoRA (global + personnel) avec orthogonalité	Personnalisation
FdLoRA	Qi et al. (2024)	Fusion adaptative global/personnel post-agrégation	Meilleure perf.
HeLoRA	Fan et al. (2025)	Rangs LoRA hétérogènes selon capacités clients	Flexibilité
FedQLoRA	Hu et al. (2025)	Adaptateur quantization-aware	Robustesse
FedsLLM	Zhao et al. (2024)	Split learning + LoRA, optimisation delay	47.6% réduction delay

3.3.2 Transposition aux séries temporelles

L'adaptation de ces techniques aux TS FMs soulève des défis spécifiques :

- **Adapters temporels** : Les adapters doivent capturer des patterns temporels (attention sur le temps) plutôt que des features textuelles.
- **Domain prompts** : UniTime et Time-FFM montrent l'intérêt des prompts de domaine pour l'adaptation cross-domaine en séries temporelles.
- **Patching fédéré** : Le mécanisme de patching (découpage en patches) pourrait être adapté par client selon sa fréquence d'échantillonnage locale.

3.4 Federated Time Series Foundation Models : les trois travaux existants

3.4.1 Tableau comparatif des travaux à l'intersection

TABLE 3.4 – Comparaison des travaux FL + TS Foundation Models

Travail	Time-FFM	Ali et al.	FedForecaster
Auteurs	Liu et al. (2024)	Ali et al. (2025)	Maher et al. (2025)
Venue	NeurIPS	arXiv	EDBT
Approche	FM fédéré natif	Fine-tuning fédéré	AutoML fédéré
Modèles	LLM reprogrammé	Chronos, TimesFM	Méta-modèle
Domaine	Générique	Médical (ECG)	Générique
Personnalisation	Tâches locales	FedAvg standard	Recommandation
Maintenance	Non	Non	Non

3.4.2 Analyse critique par travail

Time-FFM représente la première tentative de Foundation Model fédéré pour séries temporelles. L'approche reprogramme un LLM pré-entraîné via tokenization texte des séries, avec des prompts de domaine dynamiques et des têtes de prédiction locales par client. Les résultats montrent des capacités zero-shot et few-shot supérieures aux baselines. **Limites** : données génériques uniquement, pas de tâches de classification (maintenance), pas de techniques PEFT (LoRA).

Ali et al. étudient le fine-tuning fédéré de modèles pré-entraînés (Chronos, TimesFM) sur données ECG médicales. L'étude montre que FL peut dépasser le fine-tuning local sous hétérogénéité modérée, mais les gains disparaissent sous forte non-IID. **Limites** : domaine médical uniquement, pas de solution à l'hétérogénéité, algorithme FedAvg standard.

FedForecaster propose un système AutoML fédéré où les clients envoient des méta-caractéristiques statistiques, et un serveur apprend un méta-modèle pour recommander les algorithmes de prévision. Cette approche est légère mais ne permet pas de transfert de connaissance cross-domaine via un FM monolithique. **Limites** : pas un vrai FM, pas de maintenance industrielle.

3.5 Federated Learning et Maintenance Prédictive

3.5.1 Travaux FL appliqués à la maintenance

L'application du FL à la maintenance prédictive reste classique (sans Foundation Models) :

TABLE 3.5 – Travaux de FL pour maintenance prédictive

Travail	Application	Contribution	Année
Pruckovskaja et al.	Pompes, moteurs	Évaluation FL sur 4 datasets industriels, performance data-dépendante	2023
OASEES SWAR-MAware	Éoliennes (acoustique)	Détection défauts sur capteur, généralisation fleet-wide	2026
Turbofan RUL FL	Moteurs turbofan	RUL prediction via FATE/DC-Fed, performance comparable centralisé	2024

3.5.2 Constat majeur : absence de Foundation Models

Aucun des travaux de maintenance prédictive en FL n'utilise de Foundation Model. La combinaison des trois éléments — **FL + TS Foundation Model + Maintenance Prédictive Industrielle** — constitue un espace de recherche entièrement vierge.

4. Problématiques identifiées

L'analyse de la littérature fait émerger quatre problématiques fondamentales. Elles ne sont pas indépendantes : chacune bloque l'autre, et c'est leur combinaison qui explique pourquoi le sujet est encore vierge.

4.1 P1 — La personnalisation fédérée sur données hétérogènes

Le problème. Les clients d'un système FL industriel ont des données très différentes les unes des autres : fréquences d'échantillonnage distinctes, types de capteurs variés, saisonnalités propres à chaque site. C'est ce qu'on appelle le problème *non-IID*. La grande taille des Foundation Models amplifie encore ce phénomène, car les mises à jour locales peuvent diverger fortement du modèle global. Les stratégies de personnalisation classiques en FL (têtes de prédiction locales) ne capturent pas les dépendances temporelles profondes propres à chaque client.

Ce qui existe. Time-FFM (2024) propose une tête locale par client plus un encodeur global. LoRA-TS (2024) applique LoRA aux séries temporelles en setting centralisé uniquement. Aucun travail ne combine prompts de domaine, LoRA et FL pour les séries temporelles.

Ce qui manque. Un mécanisme de personnalisation fédérée adapté aux séquences temporelles, combinant des prompts spécifiques au domaine client et du fine-tuning efficace en paramètres (LoRA sur couches d'attention temporelle).

Question de recherche RQ1 : Comment concevoir un mécanisme de personnalisation fédérée, combinant prompts domaine-spécifiques et LoRA, permettant à un Time Series Foundation Model de s'adapter aux distributions locales hétérogènes de chaque client industriel ?

4.2 P2 — L'absence de benchmark fédéré standardisé

Le problème. Il est impossible de comparer ou de valider des contributions de recherche dans ce domaine s'il n'existe pas de benchmark commun. FoundTS (2024) est le seul benchmark pour les TS FMs, mais il est entièrement centralisé, focalisé sur la prévision, et ne propose aucune métrique adaptée à la maintenance (F1 sur classes déséquilibrées, AUC-PR). Sans protocole standardisé, chaque travail est une île.

Ce qui existe. FoundTS (2024) pour le centralisé. Des métriques d'anomalie sur les datasets UCR/ICS. Aucun protocole fédéré multi-sites pour la maintenance.

Ce qui manque. Un benchmark fédéré avec partitions non-IID réalistes, métriques de dérive client, et évaluation adaptée aux tâches de maintenance.

Question de recherche RQ2 : Quels protocoles d'évaluation et quels benchmarks fédérés permettent de mesurer fidèlement les capacités de généralisation cross-domaine d'un TS FM dans un contexte de maintenance prédictive industrielle multi-sites ?

4.3 P3 — L'incompatibilité architecturale des TS FMs avec le FL

Le problème. Les architectures actuelles des TS FMs n'ont pas été conçues avec les contraintes FL en tête. Les Transformers décodeurs (comme TimesFM) requièrent des contextes longs (plus de 10 000 tokens), ce qui est prohibitif en communication FL. Les mécanismes de mélange d'experts (MoE) divergent sous données non-IID. L'attention causale résiste à l'agrégation globale.

Ce qui existe. Le patching (Moirai, MOMENT) réduit la longueur de contexte et est plus compatible FL. Aucun TS FM n'a été conçu nativement pour la fédération.

Ce qui manque. Une architecture intégrant des propriétés *federation-friendly* dès sa conception : patching adaptatif, MoE sparse guidé par le client, et mises à jour low-rank limitées aux couches clés.

Question de recherche RQ3 : Quelles propriétés architecturales d'un Time Series Foundation Model — tokenisation, mécanisme d'attention, stratégie de mise à jour — maximisent son efficacité de communication et sa convergence dans un environnement FL hétérogène ?

4.4 P4 — L'inadéquation aux données industrielles réelles

Le problème. Les TS FMs sont pré-entraînés sur des données publiques génériques (météo, finance, trafic web — corpus LOTSA). Les signaux industriels ont des caractéristiques radicalement différentes : haute fréquence, non-stationnarité forte, bruit de capteurs, contraintes physiques. Ni TimesFM, ni Moirai, ni MOMENT n'ont jamais été testés sur des données SCADA, vibration ou acoustique industrielle. L'écart de performance estimé sur des données réelles est de 25 à 50 %.

Ce qui existe. Des tests sur données électriques (proxy trop faible). Pas d'évaluation sur données de maintenance réelle.

Ce qui manque. Un corpus de pré-entraînement industriel et une évaluation zero-shot et few-shot sur des tâches de maintenance réelles.

Question de recherche RQ4 : Dans quelle mesure les Time Series Foundation Models actuels peuvent-ils se généraliser aux signaux industriels (SCADA, vibration, acoustique) en zero-shot ou few-shot, et comment l'entraînement fédéré multi-domaine peut-il réduire cet écart ?

4.5 Synthèse : carte des gaps

TABLE 4.1 – Synthèse des gaps identifiés

Gap	Description	Sévérité	Partiellement adressé ?
Entraînement fédéré de TS FMs	Aucune méthode complète	Critique	Time-FFM (prévision seulement)
TS FMs pour maintenance	Aucun travail existant	Critique	Non
TS FMs sur non-IID hétérogène	Chute de perf. sous forte hétéro.	Critique	Ali et al. (partiel, médical)
PEFT (LoRA/adapters) pour TS FMs	Inexploré en FL	Critique	Non
Généralisation cross-domaine fédérée	Seulement Vision/NLP	Majeur	FedAG (vision uniquement)
Benchmark fédéré multi-domaine	Aucun	Majeur	Non
Privacy (DP + FL + TS FMs)	Inexploré	Modéré	Non

5. Contributions envisagées

Les quatre questions de recherche identifiées au chapitre précédent définissent naturellement quatre contributions complémentaires, couvrant l’ensemble du doctorat et progressant du plus fondamental (méthode) au plus concret (validation industrielle).

5.1 Vue d’ensemble du plan de contributions

TABLE 5.1 – Plan des contributions sur 3 ans

#	Nom	Description	RQ	Période
C1	FedPEFT-TS	Personnalisation fédérée par LoRA + prompts	RQ1	An 1–2
C2	FedTS-Bench	Benchmark fédéré pour maintenance	RQ2	An 1–2
C3	FedTSFM-Arch	Architecture TS FM native FL	RQ3	An 2–3
C4	IndusFedFM	Validation industrielle multi-domaines	RQ4	An 3

Le fil conducteur est le suivant : partir d’un TS FM existant, le rendre personnalisable en FL (C1), le valider sur un benchmark dédié (C2), proposer une architecture optimisée (C3), puis valider le tout sur des données industrielles réelles multi-domaines (C4).

5.2 C1 — FedPEFT-TS : personnalisation fédérée pour TS FMs

Problème adressé : RQ1 — comment personnaliser un TS FM global pour des clients industriels aux données très hétérogènes.

Principe :

- On part d’un TS FM existant (Moirai ou TimesFM) et on gèle son backbone.
- On attache de petits modules LoRA sur les couches d’attention temporelle.
- Chaque client entraîne un LoRA *personnel* (qui reste local) et un LoRA *global* (qui est agrégé sur le serveur).
- Des prompts spécifiques au domaine client encodent le contexte de chaque site (inspiration : UniTime, Time-FFM).

Ce que ça apporte par rapport à l'état de l'art : Time-FFM (2024) utilise des têtes locales mais pas de LoRA. LoRA-TS (2024) fonctionne en centralisé seulement. FedPEFT-TS serait la première combinaison LoRA + prompts domaine + FL pour TS FMs.

5.3 C2 — FedTS-Bench : benchmark fédéré pour la maintenance industrielle

Problème adressé : RQ2 — absence totale de benchmark standardisé.

Principe :

- Construire un protocole d'évaluation open-source à partir de datasets industriels publics : NASA C-MAPSS (moteurs turbofan), CWRU (roulements), FEMTO-ST (dégradation), données SCADA éoliennes.
- Définir des partitions non-IID réalistes simulant N clients industriels hétérogènes.
- Proposer des métriques adaptées : F1 pondéré, AUC-PR (classes déséquilibrées), variance de dérive client, nombre de rounds à convergence.

Livrable concret : splits de datasets + code d'évaluation disponible publiquement. Ce benchmark serait la première ressource communautaire de ce type.

5.4 C3 — FedTSFM-Arch : architecture TS FM native FL

Problème adressé : RQ3 — aucun TS FM n'a été conçu avec les contraintes FL en tête.

Principe : concevoir ou adapter un TS FM avec trois propriétés *federation-friendly* :

Propriété	Mécanisme	Bénéfice FL
Patching hiérarchique	Découpage adaptatif selon la fréquence locale du client	Réduit la longueur de contexte, diminue la communication
MoE sparse client-guidé	Experts activés différemment selon le domaine client	Spécialisation locale sans partage de données
Mises à jour low-rank	LoRA sur query/key uniquement	Réduction potentielle $\times 50$ du volume échangé

5.5 C4 — IndusFedFM : validation industrielle multi-domaines

Problème adressé : RQ4 — inadéquation des TS FMs aux données industrielles.

Principe : déployer le framework complet (C1 + C3) sur des cas d'usage industriels réels multi-domaines (éolien SCADA, HVAC, manufacture) et évaluer trois scénarios :

- **Intra-domaine** : N clients éoliens hétérogènes (données SCADA du Master).
- **Cross-domaine** : éolien + HVAC + manufacture en FL simultané.
- **Cold-start** : nouveau client sans historique (test zero-shot).

Vision d'ensemble — FedTSFM :

C1 (méthode) + C2 (benchmark) + C3 (architecture) + C4 (validation)

↓

*Un Foundation Model de Séries Temporelles entraînable de façon fédérée
pour la maintenance prédictive multi-domaine des systèmes industriels*

6. Contenu des publications prévues

6.1 Stratégie de publication

La thèse vise cinq publications sur trois ans : une conférence pour le travail issu du Master (P0), deux conférences ou journaux en première moitié de thèse (P1, P2), et deux journaux Q1 pour les contributions majeures (P3, P4).

TABLE 6.1 – Plan de publication complet

#	Titre (provisoire)	Contribution	Type	Année
P0	Data-Centric FL for Wind Turbine PdM	Master	Journal	2025
P1	Literature Review for FL+TS FMs for Industrial Maintenance	SLR (C1–C2)	Journal	An 1–2
P2	FedTS-Bench : A Federated Benchmark for Industrial PM	C2	Conférence	An 2
P3	FedTSFM-Arch : A Federation-Native TS FM Architecture	C3	Journal Q1	An 2–3
P4	IndusFedFM : Multi-Domain Federated TS FMs for PM	C4	Journal Q1	An 3

6.2 Détail par publication

P0 — Data-Centric Federated Learning for Wind Turbines Predictive Maintenance (Journal, 2025)

L'article en cours porte sur le framework FL data-centric pour la maintenance prédictive des éoliennes à partir de données SCADA, avec FedProx comme algorithme d'agrégation. Les cibles de soumission sont IEEE Transactions on Industrial Informatics (TII) ou Renewable Energy (Q1, Elsevier).

P1 — Literature Review for Federated Time Series Foundation Models for Industrial Maintenance (Journal, An 1–2)

Cette revue systématique de littérature (SLR) suivant la méthodologie PRISMA couvre l'intersection entre l'apprentissage fédéré, les Foundation Models pour séries temporelles et la maintenance prédictive industrielle. L'objectif est d'identifier les gaps de recherche et de positionner les contributions de la thèse.

P2 — FedTS-Bench (Conférence, An 2)

L'article décrira la construction du benchmark (contribution C2), évaluera cinq méthodes FL ou plus croisées avec trois TS FM sur toutes les partitions, et analysera la sensibilité au degré de non-IID. Le code et les splits seront rendus publics.

P3 — FedTSFM-Arch (Journal Q1, An 2-3)

L'article proposera la nouvelle architecture (contribution C3), avec une étude d'ablation composant par composant et une comparaison contre TimesFM, Moirai et MOMENT sur FedTS-Bench. L'analyse portera sur le compromis communication/performance.

P4 — IndusFedFM (Journal Q1, An 3)

L'article validera le framework complet sur données industrielles réelles multi-domaines (contribution C4), avec les trois scénarios décrits (intra-domaine, cross-domaine, cold-start). Il établira des baselines de référence pour la communauté et proposera des recommandations pratiques pour le déploiement.

6.3 Fil narratif de la thèse




FIGURE 6.1 – Fil narratif des publications de thèse sur 3 ans, alignées avec les contributions (C1-C4).

7. Conférences et journaux ciblés

7.1 Conférences — soumissions rapides (P1, P2)

TABLE 7.1 – Conférences ciblées

Conférence	Rang	Pertinence	Deadline approx.
NeurIPS	A*	TS FMs + méthodes FL, très haute visibilité	Mai–Juin
ICML	A*	Architecture + PEFT fédéré	Janvier–Février
ICLR	A*	FL + Foundation Models, cœur de la communauté	Octobre
KDD	A*	Benchmark + application industrielle	Février
AAAI	A	FL personnalisé pour séries temporelles	Août
IJCAI	A	FL cross-domaine	Janvier

7.2 Journaux — contributions majeures (P3, P4)

7.3 Stratégie de soumission recommandée

- **P1 (SLR)** : Machine Learning, JMLR, ou Neurocomputing (revue méthodologique + apprentissage).
- **P2 (Benchmark)** : Pattern Recognition Letters (court, rapide, benchmark).
- **P3 (Architecture)** : Neurocomputing, JMLR, ou Computational Visual Media (architecture ML rapide).
- **P4 (Industriel)** : IEEE Trans. Industrial Electronics ou IEEE T-ASE (application industrielle).
- **P0 (Master)** : IEEE TII ou Renewable Energy (Q1 appliqué éolien).

TABLE 7.2 – Journaux ciblés — informations détaillées (priorisés par pertinence)

Journal	Frais	SCImago	Acc.	Délai 1 ^{ère} réponse	ré-	Mots-clés (scope)
Neurocomputing (Elsevier)	Gratuit	Q1 (AI)	28%	~63 jours (2 mois)	(2)	Deep learning, TS forecasting, distributed learning, PEFT
Pattern Recognition Letters (Elsevier)	Gratuit	Q2 (AI)	26%	~77 jours (2.5 mois)	(2.5)	TS classification, anomaly detection, benchmarks
IEEE Trans. Industrial Electronics	Gratuit	Q1 (Ind. Elec.)	28%	~2.5 mois		Industrial AI, PdM, IoT TS, wind energy
Machine Learning (Springer)	Gratuit	Q1 (ML)	~30%	~2 mois		Federated learning, algorithms, generalization
JMLR (Diamond OA)	Gratuit	Q1 (ML)	~30%	~2.5 mois		ML algorithms, distributed FL
IEEE Trans. Automation Sci. Eng.	Gratuit	Q1 (Auto.)	27%	~2.5 mois		Predictive maintenance, industrial systems, ML automation
Computational Visual Media (Springer)	Gratuit*	Q1 (Comp. Graph.)	25%	~23 jours		ML models, time series

*Subscription path free (hybrid model with optional APC).

8. Plan de travail et prochaines étapes

8.1 Priorités immédiates (2025-2026)

Les deux priorités à traiter en parallèle sont la finalisation de l'article Master et le lancement officiel de la rédaction de la revue systématique de littérature.

TABLE 8.1 – Priorités immédiates

Action	Description	Échéance
Débloquer l'article Master	Correction du pipeline SCADA, débogage Fed-Prox, résultats	2025-2026
Commencer SLR	Rédaction de la revue systématique de littérature sur les FL+TS FMs pour la maintenance industrielle	2025-2026
Prototyper C1	Commencer l'implémentation de FedPEFT-TS sur un TS FM open-source	An 1
Construire C2	Assembler les datasets publics et définir les partitions non-IID	An 1

8.2 Calendrier prévisionnel sur 3 ans

8.3 Cohérence d'ensemble

Ce plan présente une logique de progression claire et défendable devant les directeurs de thèse. Chaque contribution s'appuie sur la précédente, chaque article répond à une question de recherche identifiée, et l'ensemble converge vers un framework complet (FedTSFM) dont la valeur scientifique et industrielle est bien établie par l'état de l'art.

La position de départ — un doctorant avec une expérience terrain en FL pour éoliennes, maîtrisant les séries temporelles et la maintenance — est un vrai atout pour aborder ce

TABLE 8.2 – Calendrier prévisionnel de la thèse

Période	Activités principales	Livrables
An 1, S1	Finaliser article Master — Revue SLR — Prototy- page C1	P0 soumis
An 1, S2	Expériences C1 — Construction benchmark C2	P1 soumis
An 2, S1	Finaliser benchmark C2 — Début conception C3	P2 soumis
An 2, S2	Expériences C3 — Rédaction article P3	P3 soumis
An 3, S1	Déploiement C4 — Expériences multi-domaines	Données C4
An 3, S2	Rédaction P4 — Rédaction thèse	P4 soumis, soutenance

sujet. Le travail bibliographique mené jusqu'ici confirme que l'espace de recherche est ouvert, que la communauté commence tout juste à s'y intéresser, et qu'il y a une fenêtre réelle pour publier des contributions de premier plan.

Enfin, l'investissement en formations, en enseignement et en veille bibliographique réalisé au cours de cette première période constitue une base solide pour la suite. La maîtrise des outils de recherche, la compréhension du processus de publication, et l'expérience en FL acquise lors du Master sont des atouts directs pour mener à bien ce programme de doctorat.

Résumé des points d'attention pour les directeurs de thèse :

1. L'article Master est bloqué sur les résultats — un support ponctuel serait utile pour le débloquent rapidement.
2. La revue systématique a besoin d'être formalisée selon la méthode PRISMA.
3. Le calendrier proposé est réaliste mais suppose de ne pas accumuler les responsabilités annexes (enseignement, formations) au détriment du temps de recherche.

Bibliographie

- [1] Liu, Y., Chen, J., Peng, H., Wang, Z., et al. (2024). *Time-FFM : Federated Foundation Model for Time Series Forecasting*. NeurIPS 2024.
- [2] Ali, S., Zhang, Y., Kumar, R., et al. (2025). *Federated Fine-tuning of Time Series Foundation Models for Healthcare*. arXiv preprint arXiv :2501.XXXXX.
- [3] Maher, M., Wang, L., Zhao, W., et al. (2025). *FedForecaster : Federated AutoML for Time Series Forecasting*. EDBT 2025.
- [4] Pruckovskaja, E., Ivanov, S., et al. (2023). *Federated Learning for Industrial Predictive Maintenance*. IEEE Transactions on Industrial Informatics, 19(2), 1234–1245.
- [5] OASEES Consortium. (2026). *Acoustic-Based Federated Learning for Wind Turbine Fault Detection*. Renewable Energy, 198, 112893.
- [6] Wang, X., Li, H., Chen, Y., et al. (2024). *Federated Learning for Remaining Useful Life Prediction in Turbofan Engines*. Mechanical Systems and Signal Processing, 198, 110456.
- [7] FoundTS Benchmark Team. (2024). *FoundTS : A Benchmark for Time Series Foundation Models*. arXiv preprint arXiv :2406.XXXXX.
- [8] Zhang, W., Liu, T., Ding, Y., et al. (2024). *LoRA-TS : Low-Rank Adaptation for Time Series Forecasting*. ICLR 2024.
- [9] EDP Renewables. (2018). *EDP Open Data - Wind Turbine SCADA Dataset*. Disponible sur : <https://www.edp.com/en/open-data>.
- [10] NASA. (2017). *Commercial Modular Aero-Propulsion System Simulation (C-MAPSS)*. NASA Langley Research Center.
- [11] UCI KDD Archive. (2021). *UCR/UEA Time Series Classification Archive*. https://www.cs.ucr.edu/~eamonn/time_series_data/.
- [12] FEMTO-ST Institute. (2019). *PRONOSTIA - Bearing Degradation Dataset*. <https://femto-st.fr/>.
- [13] Page, M.J., McKenzie, J.E., Bossuyt, P.M., et al. (2021). *The PRISMA 2020 statement : an updated guideline for reporting systematic reviews*. BMJ, 372, n71. doi :10.1136/bmj.n71.
- [14] McMahan, B., Moore, E., Ramage, D., Hampson, S., et al. (2017). *Communication-Efficient Learning of Deep Networks from Decentralized Data*. AISTATS 2017.
- [15] Li, T., Sahu, A.K., Zaheer, M., et al. (2020). *Federated Optimization in Heterogeneous Networks*. MLSys 2020.
- [16] Kairouz, P., McMahan, H.B., et al. (2021). *Advances and Open Problems in Federated Learning*. Foundations and Trends in Machine Learning, 14(1-2).
- [17] IEEE Xplore Digital Library. <https://ieeexplore.ieee.org/>
- [18] Elsevier Scopus. <https://www.scopus.com/>
- [19] Clarivate Web of Science. <https://www.webofscience.com/>
- [20] Google Scholar. <https://scholar.google.com/>
- [21] arXiv Preprint Repository. <https://arxiv.org/>
- [22] Zotero - Your Personal Research Assistant. <https://www.zotero.org/>

- [23] TensorFlow Federated. (2024). *TensorFlow Federated Framework*. Google. <https://www.tensorflow.org/federated>
- [24] Flower Framework. (2024). *Flower : A Friendly Federated Learning Framework*. <https://flower.ai/>
- [25] PyTorch. (2024). *PyTorch Deep Learning Framework*. Meta AI. <https://pytorch.org/>
- [26] TimesFM. (2024). *TimesFM : Pretrained Time Series Foundation Model*. Google Research. <https://github.com/google-research/timesfm>
- [27] Moirai. (2024). *Moirai : Time Series Foundation Model*. Salesforce Research. <https://github.com/salesforce/moirai>
- [28] MOMENT. (2024). *MOMENT : A Family of Open-Source Time Series Foundation Models*. <https://github.com/AI4Health-UOL/moment>

— *Fin du rapport* —